OUTIL D'ANALYSE FOOTBALL · DONNÉES WYSCOUT

SCOUTANALYTICS

MÉTHODOLOGIE

Ce document explique comment les données sont contrôlées, comment les équipes et les joueurs sont analysés, comment fonctionne la recherche de profils et ce qui a été vérifié. Il décrit la version 2 de l'outil, telle qu'elle est présentée sur le portfolio.



TOM HAMEL

Analyste de performance · Data · Vidéo

Version 2
Octobre 2026

01 PRINCIPES

ScoutAnalytics sert à analyser une équipe (la sienne ou un adversaire), à analyser un joueur et à chercher des joueurs selon un besoin précis. Quatre règles guident toute la méthode.

- **L'outil ne décide pas ce qu'est un bon joueur.** Aucune note globale n'est attribuée. Un joueur est décrit statistique par statistique, et la recherche classe les joueurs selon les priorités que l'utilisateur fixe lui-même.
- **Un joueur est comparé aux joueurs de la même fonction.** Un latéral est comparé aux latéraux, un milieu défensif aux milieux défensifs.
- **Le contexte n'est pris en compte que là où il a été démontré.** Une lecture contextuelle n'existe que pour les statistiques où une étude préalable a montré que le style et le niveau de l'équipe pèsent réellement (partie 4).
- **Une valeur manquante reste manquante.** Elle n'est jamais remplacée par zéro ni estimée en silence. Un taux sans tentative est absent ; une lecture impossible est signalée avec sa raison.

02 DES DONNÉES CONTRÔLÉES

Les exports Wyscout passent par un import contrôlé avant d'entrer dans une base SQL. Le carnet d'analyse lit ensuite cette base sans jamais la modifier.

LES EXPORTS

- **Joueurs** : un fichier par championnat et par saison (115 colonnes), une ligne par joueur et par club.
- **Team Stats avec adversaires** : un fichier par équipe et par saison (109 colonnes), avec pour chaque match la ligne de l'équipe et celle de son adversaire.

L'IMPORT

L'import se lance en une commande, dossier par dossier (une saison, un championnat). Avant toute écriture, la base est sauvegardée. Chaque fichier est ensuite reconnu, contrôlé puis importé, et le résultat est consigné dans un journal.

- **Contrôles de forme** : type de fichier, colonnes attendues, saison, championnat déclaré. Un fichier non conforme est refusé avec la raison ; rien n'est écrit pour lui.
- **Pas de doublon** : un fichier déjà importé est reconnu par son empreinte et ignoré. Relancer un import ne change rien.
- **Mises à jour en cours de saison** : un nouvel export remplace l'ancien de façon explicite ; une valeur corrigée par Wyscout remplace l'ancienne, qui est archivée.
- **Matchs** : chaque match doit avoir deux lignes et deux côtés cohérents. Un doublon probable n'est jamais fusionné automatiquement ; il est signalé et tranché à la main. Deux matchs joués le même jour avec le même libellé (matchs amicaux) restent deux matchs distincts.
- **Annulation** : le dernier import peut être annulé en remettant la sauvegarde.

L'IDENTITÉ DES JOUEURS

Wyscout ne fournit pas d'identifiant de joueur et n'écrit pas toujours un nom de la même façon. Un joueur est relié d'une saison à l'autre seulement si tout concorde : initiale et nom, pays de naissance et passeport commun, âges cohérents, et au moins un indice de plus (même écriture, même taille ou même club). Deux

joueurs du même nom dans le même club restent deux joueurs. Les cas douteux sont tranchés à la main, et chaque décision est conservée.

Il arrive aussi que Wyscout ait deux fiches pour un même joueur dans un même export (matchs et minutes qui se recoupent). L'import le signale ; la fiche écartée reste en base mais n'est plus lue. Un transfert en cours de saison, lui, donne deux lignes justes, une par club.

LA BASE ET SA LECTURE

La base SQLite garde les données telles que Wyscout les fournit, plus les décisions prises à l'import. Des vues prêtes à l'emploi donnent une ligne par joueur et par saison, par équipe et par match (avec les statistiques de l'adversaire) et par équipe et par saison. Le carnet d'analyse (Python, Google Colab) ouvre la base en lecture seule, affiche son empreinte à chaque exécution, et refuse une base absente ou une saison absente.

03 L'ANALYSE DES ÉQUIPES

Une équipe est décrite de deux façons : son identité de jeu (comment elle joue) et ses performances collectives (ce qu'elle produit et concède). Toutes les valeurs viennent des Team Stats, match par match.

L'IDENTITÉ DE JEU : 7 AXES

Chaque axe est une proportion ou une moyenne sur la saison. Les parts sont calculées sur les totaux de la saison, pas en moyennant des pourcentages de matchs.

AXE	CALCUL
Jeu court	100 - part moyenne de passes longues
Centres	entrées dans la surface sur centre ÷ entrées dans la surface
Transition	contre-attaques ÷ (contre-attaques + attaques placées)
Pressing	PPDA moyen, en sens inverse (moins de passes adverses permises = pressing plus intense)
Récupération haute	récupérations dans le dernier tiers ÷ récupérations
Pertes dans son camp	pertes dans son tiers défensif ÷ pertes
Coups de pied arrêtés	tirs sur coup de pied arrêté ÷ tirs (attaques placées, contre-attaques, coups de pied arrêtés)

ÉCART ROBUSTE, TENDANCE OU DANS LA MOYENNE

Chaque équipe est comparée à la médiane de son championnat, ou des championnats chargés. Pour savoir si l'écart est solide ou dû à quelques matchs, ses matchs sont rééchantillonnés 500 fois (tirage avec remise, graine fixe pour des résultats reproductibles), et l'écart à la médiane est recalculé à chaque tirage.

- **Écart robuste** : l'intervalle à 95 % de l'écart ne contient pas zéro.
- **Tendance** : seul l'intervalle à 80 % ne contient pas zéro.
- **Dans la moyenne** : l'écart ne se distingue pas de zéro. Cela ne veut pas dire que l'équipe est exactement moyenne.

Deux axes sont moins stables que les autres d'une moitié de saison à l'autre : transition (0,51) et coups de pied arrêtés (0,52), fiabilité mesurée en coupant les matchs en deux moitiés (correction de Spearman-Brown). Leurs conclusions demandent plus de prudence.

Le système principal (le plus utilisé sur la saison) vient de la formation que Wyscout attribue à chaque match. Le schéma affiché représente ce système, pas les positions réelles des joueurs.

LES PERFORMANCES COLLECTIVES

64 statistiques par match, réparties en 8 groupes, avec pour chacune le sens dans lequel une valeur est favorable (beaucoup de tirs, peu de tirs concédés). Elles servent à classer les équipes sur une statistique, à comparer deux équipes et à situer une équipe par rapport à la médiane.

04 L'ANALYSE DES JOUEURS

Chaque statistique d'un joueur est donnée sous forme de percentile parmi les joueurs de sa fonction. Quand l'étude l'a justifié, une seconde lecture tient compte du contexte de son équipe.

FONCTIONS DE RÉFÉRENCE

Le poste vient des positions Wyscout du joueur, puis il est précisé : gardien (GK), défenseur central (CB), latéral (FB), piston (WB), milieu défensif (DM), milieu central (CM), milieu offensif (AM), ailier (W), attaquant (CF). Les latéraux gauche et droit sont réunis, comme les ailiers. Un seuil de minutes jouées, réglable, écarte les joueurs qui ont trop peu joué.

LA LECTURE GÉNÉRALE

Le percentile général situe le joueur parmi tous les joueurs de sa fonction dans les championnats chargés. Les ex aequo reçoivent le rang moyen ; les valeurs manquantes sont ignorées, pas comptées comme des zéros. Le catalogue compte 78 statistiques, dont deux calculées par l'outil : la part de passes progressives et l'xG hors penalty.

LA LECTURE CONTEXTUELLE

Un milieu touche plus de ballons dans une équipe qui a le ballon ; un défenseur défend plus dans une équipe dominée. La lecture contextuelle retire cet effet : elle compare le joueur à ce qu'on attend d'un joueur de sa fonction dans une équipe comme la sienne.

```
valeur attendue = modèle linéaire (5 facteurs d'équipe + championnat)
percentile contextuel = rang de (valeur réelle − valeur attendue) parmi les joueurs de la fonction
```

FACTEUR D'ÉQUIPE	MESURE
Possession	possession moyenne
Hauteur du bloc	récupérations dans le dernier tiers ÷ récupérations
Jeu direct	part de passes longues
Transitions	contre-attaques par match
Niveau	différence moyenne d'xG par match (différence de buts si les données adverses manquent)

Le modèle est ajusté séparément pour chaque statistique et chaque fonction, avec au moins 30 joueurs et 15 équipes. Si l'un des cinq facteurs manque pour l'équipe du joueur, il n'a pas de lecture contextuelle, et la raison est affichée.

L'ÉTUDE DE CONTEXTUALISATION

Avant de modifier l'outil, une étude a testé, pour chaque statistique et chaque fonction, si le contexte d'équipe pèse vraiment. Elle porte sur la saison 2025-26 de 8 championnats européens : 2 556 joueurs à 900 minutes ou plus, dont 186 gardiens, et 148 équipes. 547 combinaisons statistique × fonction ont été examinées.

Pour chacune, l'étude a regardé la part des différences entre joueurs liée à l'équipe, l'ampleur de l'effet, sa stabilité championnat par championnat, sa robustesse sur cinq variantes du modèle, et si son sens correspondait à l'hypothèse écrite avant l'analyse. Le protocole ne fixait pas de seuils chiffrés à l'avance ; les décisions ont suivi une ligne régulière, consignée avec chaque cas.

STATUT	COMBINAISONS	DANS L'OUTIL
Net	135	lecture contextuelle
Modéré	79	lecture contextuelle, signalée « influence modérée »
Exploratoire	7	lecture contextuelle, signalée « exploratoire »
Exploratoire, suspendu	7	percentile général seul (hypothèse à reformuler)
Non retenu	277	percentile général seul
Non évaluable	42	percentile général seul (plus de la moitié des joueurs à zéro)

Le contexte compte pour presque tout le jeu de passe, la progression, la création chez les milieux, ailiers et attaquants, le volume offensif (tirs, xG, touches dans la surface), une partie du volume défensif, et tout ce que subit le gardien.

Aucune correction n'est retenue pour la réussite dans les duels et les dribbles, la qualité de finition, les centres, les coups de pied arrêtés et les buts évités. Cela ne prouve pas l'absence de lien : la correction n'était pas assez justifiée.

Les décisions sont lues par l'outil dans un seul fichier de référence ; rien n'est codé en dur. Toute révision y est datée et justifiée.

LES TAUX ET LEURS DÉNOMINATEURS

- Pour chaque taux, l'outil affiche le nombre de tentatives de la saison : compte réel quand l'export le fournit, estimation sinon (valeur par 90 × minutes ÷ 90), signalée comme telle.
- Quatre valeurs par 90 sont recalculées à partir des totaux de la saison, plus précis que les valeurs arrondies de l'export : xG, xA, buts hors penalty et tirs.
- L'xG hors penalty est estimé en retirant 0,76 xG par penalty tiré.
- Le dénominateur des « duels de marquage, % » a été vérifié : les duels gagnés qu'il donne tombent sur un nombre entier pour 100 % des 2 698 joueurs testés (900 minutes et plus), contre 15 % et 22 % avec deux autres dénominateurs possibles.

05 PROFILS, JOUEURS SIMILAIRES ET RECHERCHE

Trois usages reposent sur les mêmes percentiles : lire le profil d'un joueur, trouver des profils proches et chercher selon un besoin.

LE RADAR ET LES POINTS FORTS

Chaque fonction a un radar par défaut de 7 à 11 statistiques (liste en annexe), modifiable parmi le catalogue de la fonction. Le radar s'affiche en lecture générale ou contextuelle. Les points forts et les points faibles sont pris parmi les axes du radar.

LES JOUEURS SIMILAIRES

Les joueurs similaires sont cherchés dans la même fonction, sur les percentiles de la lecture générale des axes par défaut du radar. Seuls les axes renseignés chez les deux joueurs sont comparés, et un candidat doit en partager au moins 60 % (et au moins 3).

```
similarité = 100 − √(moyenne des carrés des écarts de percentile)
```

LA RECHERCHE DE PROFILS

L'utilisateur choisit une fonction, les statistiques qui comptent pour lui et leur poids. Il peut filtrer par âge, minutes, valeur marchande et fin de contrat.

```
score de la recherche = moyenne pondérée des percentiles des statistiques choisies
```

Sans statistique pondérée, il n'y a pas de score. Le résultat dépend des priorités choisies : pour un même poste, deux clubs aux besoins différents obtiennent deux classements différents.

06 VÉRIFICATIONS

Chaque évolution est testée avant d'être adoptée, en comparant les résultats avant et après.

- **Base et fichiers d'origine.** Pour la saison 2025-26 des 8 championnats, le dashboard produit depuis la base SQL est identique à l'octet près à celui produit directement depuis les exports Excel, à 45 et à 900 minutes. Les 148 exports Team Stats sont restitués par la base exactement comme dans les fichiers (valeurs, types, ordre).
- **Import.** Des suites de tests automatiques couvrent les fichiers refusés, les réimports, les mises à jour, les doublons de matchs, les matchs du même jour et les liens entre joueurs.
- **Carnet.** Les garde-fous sont testés : base absente, saison absente, mauvais fichier, et toute tentative d'écriture échoue.
- **Dashboard.** Lors du nettoyage du code, les données et l'affichage ont été comparés avant et après, dans les trois langues et sur plusieurs joueurs et équipes. Un contrôle négatif a confirmé que la comparaison détecte une seule valeur modifiée.
- **Calculs.** Les intervalles de l'identité de jeu sont vérifiés à chaque exécution (l'intervalle à 80 % est toujours compris dans celui à 95 %). Le pourcentage d'arrêts a été recalculé à partir des tirs contre et des buts concédés pour les 186 gardiens. Les décisions de l'étude ont été comparées automatiquement au fichier lu par l'outil : aucun écart.

07 LIMITES

- **Données de jeu uniquement.** Wyscout ne fournit pas de données physiques. L'outil dit si un joueur se distingue dans sa fonction, dans un contexte comparable ; il ne dit pas s'il s'adaptera à un système donné.
- **Validation à venir.** Les décisions de l'étude doivent encore être confirmées sur un jeu de données indépendant, avec une règle de décision figée avant de regarder ces données. Les effets exploratoires et les petits effectifs (milieux offensifs, gardiens) sont prioritaires.
- **Contexte n'est pas cause.** La lecture contextuelle retire l'effet moyen du style et du niveau de l'équipe ; elle ne mesure pas l'influence d'un joueur sur son équipe.
- **Dénominateurs estimés.** Pour la plupart des taux, le nombre de tentatives est estimé ; la cohérence est vérifiée, pas le dénominateur exact de Wyscout.
- **Données du jour de l'export.** L'âge, la valeur marchande, le contrat et le club actuel sont ceux du jour de l'export, pas de la saison. Wyscout recalcule parfois ses modèles (xG) : deux saisons exportées à des dates éloignées ne sont pas forcément calculées de la même façon.

Les données Wyscout sont sous licence : elles ne sont ni publiées ni reproduites dans ce document. L'outil complet est présenté en entretien.

A ANNEXE : RADARS PAR DÉFAUT

Statistiques affichées par défaut sur le radar de chaque fonction. L'utilisateur peut en retirer ou en ajouter parmi le catalogue de la fonction.

FONCTION	AXES PAR DÉFAUT
GK	Buts évités/90 · % arrêts · Sorties/90 · Duels aériens/90 · Passes/90 · % passes réussies · Passes longues/90 · % passes longues réussies
CB	Duels déf./90 · % duels déf. gagnés · Interceptions/90 · Tirs contrés/90 · Duels aériens/90 · % duels aériens gagnés · Passes/90 · % passes réussies · Passes prog./90 · % passes longues réussies · Conduites prog./90
FB	Duels déf./90 · % duels déf. gagnés · Interceptions/90 · Passes prog./90 · Conduites prog./90 · Centres/90 · xA/90
WB	Duels déf./90 · % duels déf. gagnés · Interceptions/90 · Passes prog./90 · Conduites prog./90 · Centres/90 · xA/90 · Touches surface/90
DM	Duels déf./90 · % duels déf. gagnés · Interceptions/90 · % duels aériens gagnés · Passes/90 · % passes réussies · Passes prog./90 · % passes longues réussies · Conduites prog./90
CM	Duels déf./90 · % duels déf. gagnés · Passes/90 · Passes prog./90 · Conduites prog./90 · xA/90 · xG hors pén./90
AM	xA/90 · Passes clés/90 · Passes dans la surface/90 · xG hors pén./90 · Touches surface/90 · Dribbles/90 · % dribbles réussis · Conduites prog./90
W	Dribbles/90 · % dribbles réussis · Conduites prog./90 · xA/90 · Passes dans la surface/90 · xG hors pén./90 · Touches surface/90
CF	xG hors pén./90 · Tirs/90 · Tirs cadrés % · Touches surface/90 · Passes clés/90 · Duels off./90 · Conduites prog./90